

凸优化笔记1.

1. 仿射集 affine set

$\forall \theta x_1, x_2 \in C, \theta \in \mathbb{R}$, 有 $\theta x_1 + (1-\theta)x_2 \in C$.

则 C 为仿射集

即：任意 x_1, x_2 在 C 中，直线 x_1, x_2 也在 C 中，则 C 是仿射

2. 仿射组合 affine combination.

设 $x_1, x_2, \dots, x_n \in C$. 若 $\theta_1, \dots, \theta_n \in \mathbb{R}$ 且 $\sum \theta_i = 1$.

将 $\theta_1 x_1 + \theta_2 x_2 + \dots + \theta_n x_n$ 称为仿射组合.

$$\sum \theta_i x_i \in C$$

3. 仿射包 affine hull.

$$aff C = \{x_1 \theta_1 + \dots + x_n \theta_n \mid x_1, \dots, x_n \in C, \theta_1 + \dots + \theta_n = 1\}$$

4. 凸集 convex set

一个集合是凸的，若 C 中任意两点之间连线段都在 C 中.

$\forall (\theta x_1, x_2) \in C, \forall \theta \in [0, 1], \theta x_1 + (1-\theta)x_2 \in C$.

5. 凸组合.

设 $x_1, \dots, x_n \in C$. $\theta_1 + \dots + \theta_n = 1$. 则 $\theta \geq 0$

$\theta_1 x_1 + \dots + \theta_n x_n$ 称为凸组合.

6. 凸包 convex hull.

$$conv C = \left\{ \sum \theta_i x_i \mid x_i \in C, \theta_i \geq 0, \sum \theta_i = 1 \right\}$$

7. 锥 cone

如果对 $\forall x \in C, \theta > 0$ 都有 $\theta x \in C$. 则称 C 为锥. 锥必过原点.

8. 凸锥.

对 $\forall x_1, x_2 \in C, \theta_1, \theta_2 \geq 0$

都有 $x_1 \theta_1 + x_2 \theta_2 \in C \Rightarrow C$ 为凸锥.

凸优化笔记2.

1. 凸函数

$f: \mathbb{R}^n \rightarrow \mathbb{R}$ 是凸的, 如果

① 定义域 $\text{dom}(f)$ 是凸集

② $\forall x, y \in \text{dom}(f), \theta \in [0, 1]$

有 ~~$f(\theta x + (1-\theta)y) \leq \theta f(x) + (1-\theta)f(y)$~~




2. 一阶条件

f 是凸函数, iff..

① $\text{dom}(f)$ 为凸集

② $\forall x, y \in \text{dom}(f)$, 有 $f(y) \geq f(x) + \nabla f(x)^T (y - x)$



因此, 对于可微凸函数若 $\nabla f(x_0) = 0$.

则 x_0 是极小值点.

3. 二阶条件

f 是凸函数, iff. ① $\text{dom}(f)$ 为凸集

② $\forall x \in \text{dom}(f)$, $\nabla^2 f(x) \succeq 0$

其中, $\nabla^2 f(x)$ 为 Hessian 矩阵 $H(x)$.

$$\nabla^2 f(x) = H(x) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1 \partial x_1} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_n \partial x_n} \end{bmatrix}$$

当 $H(x) \succeq 0$ 为(半正定矩阵)时, f 是凸函数.

4. 下水平集

$f: \mathbb{R}^n \rightarrow \mathbb{R}$ 的下水平集为 $C_x = \{x \in \text{dom} f \mid f(x) \leq x\}$

5. 范数

满足以下条件的函数 $f: \mathbb{R}^m \rightarrow \mathbb{R}$, $\text{dom}(f) = \mathbb{R}^m$ 称为范数.

① f 非负: $\forall x \in \mathbb{R}^m$, $f(x) \geq 0$

② f 正定: 仅对 $x=0$, $f(x)=0$

③ f 齐次: 对所有 $x \in \mathbb{R}^m$, $t \in \mathbb{R}$ 有 $f(tx) = |t|f(x)$

④ f 满足三角不等式: $\forall x, y \in \mathbb{R}^m$, $f(x+y) \leq f(x) + f(y)$

凸优化笔记3.

1. 凸优化问题.

$$\text{求} \min_x f(x)$$

$$\text{s.t. } \begin{cases} g_i(x) \leq 0 & i=1 \dots m \\ h_j(x) = 0 & j=1 \dots p \end{cases}$$

其中 $x \in \mathbb{R}^n$ 为优化变量.

$f(x), g_i(x)$ 为凸函数.

$h_j(x)$ 为仿射函数.

定义凸问题定义域为 $\mathcal{D} = \text{dom}(f) \cap \left(\bigcap_{i=1}^m \text{dom}(g_i) \right) \cap \left(\bigcap_{j=1}^p \text{dom}(h_j(x)) \right)$.

当 $x \in \mathcal{D}$ 且满足 $g_i(x) \leq 0, h_j(x) = 0$ 时, 称 x 是可行的. 由这样 x 构成可行域.

可行域中使 $f(x)$ 最小的 x^* 为最优点, 目标函数的值为最优值 $p^* = f(x^*)$.

凸优化问题是的基本性质: 任意局部最优解就是全局最优解.

2. 示性函数.

对于凸集 C , 它的示性函数为 $\mathbb{I}_C(x) = \begin{cases} 0 & \text{if } x \in C \\ \infty & \text{if } x \notin C \end{cases}$.

此处必是 $g_i(x) \leq 0$, 而非 $g_i(x) \geq 0$.
 因为凸函数下水平集总是凸集
 若写成 $g_i(x) \geq 0$, 则可行域不一定为凸集
 算法不可以保证得到全局最优解.

4. 支瓶函数

设函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$


定义函数 $f^*: \mathbb{R}^n \rightarrow \mathbb{R}$ 为

$$f^*(u) = \sup_{x \in \text{dom}(f)} \{ u^T x - f(x) \}.$$

称 f^* 为 f 的支瓶函数。

无论 f 是否为凸函数， f^* 都为凸函数。

e.g. 当 $f: \mathbb{R} \rightarrow \mathbb{R}$. 给定 u .



e.g. $f(x) = -\log(x)$.

$$f^*(u) = \sup_{x > 0} \{ ux + \log(x) \}$$

e.g. $f(x) = e^x$.

$$f^*(u) = \sup_{x \in \mathbb{R}} \{ ux - e^x \}$$

对于固定的 u . 令 $ux + \log x$ 对 x .

$$\text{求导数为 } 0 \Rightarrow u + \frac{1}{x} = 0$$

$$\Rightarrow f^*(u) = -\log(-u) - 1$$

$$\frac{\partial (ux - e^x)}{\partial x} = u - e^x = 0 \Rightarrow x = \ln u.$$

$$\therefore f^*(u) = u \ln u - u.$$

4. 对偶范数.

令 $\|\cdot\|$ 为 \mathbb{R}^n 上的范数, 对应的对偶范数用 $\|\cdot\|_*$ 表示.

$$\|z\|_* = \sup \{ z^T x \mid \|x\| \leq 1 \}$$

即. 对于 $z \in \mathbb{R}^n$, 其对偶范数是寻找一个向量 $x \in \mathbb{R}^n$,
 $\|x\| \leq 1$, 使得 x 与 z 内积最大, 这个最大内积就是
是 z 的对偶范数.

$\|\cdot\|$ 的对偶范数是 ℓ_∞

ℓ_p 的对偶范数是 ℓ_q . ($\frac{1}{p} + \frac{1}{q} = 1$)

范数的共轭函数是示性函数

若 $f(x) = \|x\|$, 则它的共轭函数是

$$f^*(y) = \begin{cases} 0 & \|y\|_* \leq 1 \\ \infty & \text{otherwise} \end{cases} = \mathbb{I}_{\{z : \|z\|_* \leq 1\}}(y)$$

用共轭函数定义, $f(x) = \|x\|$ 的共轭函数为 $f^*(y) = \sup \{ y^T x - \|x\| \}$

(1) 假设 $\|y\|_* > 1$, 则存在 $z \in \mathbb{R}^n$, $\|z\| \leq 1$, 使得 ~~$y^T z \geq 1$~~ ,

由于 $x \in \mathbb{R}^n$, 取 $x = t \cdot z$, 则 $f^*(y) = \sup \{ t(y^T z - \|z\|) \}$

令 $t \rightarrow \infty$, 则 $f^*(y) \rightarrow \infty$

(2) 若 $\|y\|_* \leq 1$, 对 $\forall x$, 有 $y^T x \leq \|x\| \cdot \|y\|_*$

$\therefore y^T x \leq \|x\|$, 当 $x=0$ 时, $f^*(y)$ 有最大值 0.

凸优化笔记4.

1. 近端梯度下降算法 proximal gradient descent

可以快速求解凸优化问题。

目标函数在某些地方不可微，但可以拆成可微部分
 g 与不可微部分 h 之和

$$\min f(x) = \min \left\{ \underset{\text{凸函数}}{\underset{\text{可微}}{\uparrow}} g(x) + \underset{\text{凸函数}}{\underset{\text{未必可微}}{\uparrow}} h(x) \right\}$$

✓ 近端映射。

近端映射定义：

$$\text{prox}_{h,t}(x) = \arg \min_{z \in \mathbb{R}^n} \frac{1}{2t} \|x - z\|_2^2 + h(z)$$

即对于给定 x , 找到 $z = \text{prox}_{h,t}(x)$ 使得 $\frac{1}{2t} \|x - z\|_2^2 + h(z)$ 最小,
这样所得到的 z 很接近且接近原不可微函数 x .
且 h 很小。

✓ 梯度迭代。

选择初始点 $x^{(0)}$: 重复。

$$x^{(k)} := \text{prox}_{h,t_k}(x^{(k-1)} - t_k \nabla g(x^{(k-1)}))$$

即梯度下降后再在附近找一个可微的点作为这次更新值。

用可微的函数 g .

✓ 近端映射的n个特殊形式 $h(x) = 0$ 或 $\mathbb{I}_C(x) \leq \|x\|_1, w$.

① 常规梯度下降.

$$\text{令 } h(x) = 0$$

$$\begin{aligned} \text{近端映射 } \text{prox}_t(x) &= \arg \min_z \frac{1}{2t} \|x - z\|_2^2 + 0 \\ &= x. \end{aligned}$$

$$\therefore \text{更新策略: } x^{(k)} = x^{(k-1)} - t_k \cdot \nabla g(x^{(k-1)})$$

② 常规投影梯度下降.

$$h(x) = \mathbb{I}_C(x)$$

$$\begin{aligned} \text{近端映射: } \text{prox}_t(x) &= \arg \min_z \frac{1}{2t} \|x - z\|_2^2 + \mathbb{I}_C(z) \\ &= \arg \min_{z \in C} \frac{1}{2t} \|x - z\|_2^2 \end{aligned}$$

$$= \arg \min_{z \in C} \frac{1}{2t} \|x - z\|_2^2$$

= $P_C(x)$. ($P_C(\cdot)$ 为 C 上的投影算子).

$$\text{更新: } x^{(k)} = P_C \left(x^{(k-1)} - t_k \cdot \nabla g(x^{(k-1)}) \right).$$


③ 软阈值算子.

$$\text{令 } h(x) = \|x\|_1$$

$$\begin{aligned} \text{近端映射 } \text{prox}_t(x) &= \arg \min_z \frac{1}{2t} \|x - z\|_2^2 + \|z\|_1 \\ &= \arg \min_z \|x - z\|_2^2 + 2t \cdot \|z\|_1 \\ &= S_t(x) \end{aligned}$$

用 $[S_t(x)]_i$ 表示 $S_t(x)$ 的第 i 个分量.

$$[S_t(x)]_i = \begin{cases} x_i - t, & x_i > t \\ 0, & |x_i| \leq t \\ x_i + t, & x_i < -t \end{cases}$$



对形如 $\arg \min_x \|x - b\|_2^2 + \gamma \|x\|_1$ 这样的目标函数, 它的解为 x^* , 第 i 个分量为.

$$x_i^* = [S_{\frac{\gamma}{2}}(b)]_i$$

✓ 近端梯度下降求 Lasso.

Lasso 问题

$$f(\beta) = \frac{1}{2} \|y - X\beta\|_2^2 + \gamma \|\beta\|_1.$$

$f(\beta)$ 可拆为 $\frac{1}{2} \|y - X\beta\|_2^2$ 和 $\gamma \|\beta\|_1$.

$$\begin{aligned}\text{prox}_t(\beta) &= \underset{\zeta}{\operatorname{argmin}} \frac{1}{2t} \|\beta - \zeta\|_2^2 + \gamma \|\zeta\|_1 \\ &= \underset{\zeta}{\operatorname{argmin}} \|\beta - \zeta\|_2^2 + 2t\gamma \|\zeta\|_1 \\ &= S_{t\gamma}(\beta)\end{aligned}$$

由于 $\nabla g(\beta) \nabla g(\beta) = -X^T(y - X\beta)$

更新策略: $\beta^{(k)} = \cancel{\beta^{(k-1)}} S_{t\gamma}(\beta^{(k-1)} + t_k X^T(y - X\beta^{(k-1)}))$.

凸优化笔记5. 一阶梯度下降.

解决目标函数并不总是处处可导的问题.

优势: 比传统方法处理问题范围更大.

缺点: 收敛速度更慢.

✓ 向量. 若 f 为凸函数, 则 $\forall x, y \in \text{dom } f$

$$f(y) \geq f(x) + \nabla f(x)^T (y - x)$$

类比一阶条件, 给定函数 f , 对 $\forall y \in \text{dom } f$

$$f(y) \geq f(x) + g^T (y - x)$$

则 g 是 f 在 x 处的一阶梯度.

✓ 将 f 在 x 处所有一阶梯度构成的集合称为 f 在 x 处的次微分. Subdifferential.

记为 $\partial f(x)$ (次微分是集合).

• 凸函数的一阶梯度总是非空.

• 非凸函数即使可微也不一定有次梯度.

• 凸函数的次梯度是空集.

✓ 次梯度计算.

设函数 f 在 x_0 处不一定可导.

$$\text{左导数 } a = \lim_{x \rightarrow x_0^-} \frac{f(x) - f(x_0)}{x - x_0}$$

$$\text{右导数 } b = \lim_{x \rightarrow x_0^+} \frac{f(x) - f(x_0)}{x - x_0}$$

凸函数 f 在 x_0 的次微分 $\partial f(x_0) = [a, b]$

$[a, b]$ 中任何一个取值都是次梯度.

✓ 次梯度优化条件.

x^* 处的.

当 x^* 是函数 f 的最优解, 当且仅当次微分中包含 0.

$$\text{即 } f(x^*) = \min_x f(x) \Leftrightarrow 0 \in \partial f(x^*)$$

✓ 次梯度优化算法.

$$x^{(k)} = x^{(k-1)} - t_k \cdot g^{(k-1)}$$

$g^{(k-1)}$ ~~也~~ $\in \partial f(x^{(k-1)})$ 即从次微分中随机选择一个次梯度作为梯度.

为了保证更新的参数使 $f(x)$ 下降, 只有当次梯度计算所使用的 t_k 更小才更新 x .

✓ 次梯度求解 lasso 问题.

$$\text{lasso: } \min_{\beta} \frac{1}{2} \|y - X\beta\|_2^2 + \lambda \|\beta\|_1$$

由次梯度优化条件, 0是该目标函数
在最优解上次微分的一个元素.

$$\text{即. } 0 \in \partial \left(\frac{1}{2} \|y - X\beta\|_2^2 + \lambda \|\beta\|_1 \right)$$

$$0 \in -X^T(y - X\beta) + \partial \lambda \|\beta\|_1$$

$$\Rightarrow \text{记 } v = \partial \|\beta\|_1$$

$$X^T(y - X\beta) = \lambda \cdot v$$

由次梯度计算方式, 得 v 的第 i 分量满足

$$v_i = \begin{cases} 1, & \beta_i > 0 \\ -1, & \beta_i = 0 \\ -1, & \beta_i < 0 \end{cases}$$

为简单起见, 假设 $X = I$, 则 $\beta = y - \lambda v$

当 $\beta_i > 0$ 时, $v_i = 1$, $\beta_i = y_i - \lambda > 0 \Rightarrow y_i > \lambda$

当 $\beta_i = 0$ 时, $|v_i| \leq 1$, $|y_i| = \lambda |v_i| < \lambda \Rightarrow$

当 $\beta_i < 0$ 时, $v_i = -1$, $\beta_i = y_i + \lambda < 0 \Rightarrow y_i < -\lambda$.

$$\text{即. } \beta_i^* = [S_\lambda(y)]_i$$

凸优化笔记6.

① 把问题转化为对偶问题，使其便于求解。

对偶性是凸优化的核心内容。(duality)

1. 原始问题及其转化。

原始问题 $\min_x f_0(x)$

$$\text{s.t. } f_i(x) \leq 0, i=1 \dots m.$$

$$h_j(x) = 0, j=1 \dots p.$$

2. 拉格朗日函数. Lagrangian function.

$$L(x, \lambda, v) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{j=1}^p v_j h_j(x).$$


3. 拉格朗日对偶函数 Lagrangian dual function.

对 Lagrangian 对 x 取下确界得到。

$$g(\lambda, v) = \inf_x L(x, \lambda, v)$$

对偶函数有如下两条重要性质：

① 对偶函数一定是凹函数。(其凹性与原目标函数和约束条件无关)



② 对 $\forall \lambda \geq 0, \forall v$ ，如果原始问题的最优值为 P^* ，
 则 $g(\lambda, v) \leq P^*$

证明：设最优解为 x^*

$$\begin{aligned} \therefore L(x^*, \lambda, v) &= f_0(x^*) + \sum_{i=1}^m \lambda_i f_i(x^*) + \sum_{j=1}^p v_j h_j(x^*) \\ &\leq f_0(x^*) = P^* \end{aligned}$$

假设 x^* 在 x_i 处取得。(①中已证明)

$$\therefore L(x^*, \lambda, v) = g_i(\lambda, v)$$

由上图知， $g(\lambda, v)$ 总在 $g_i(\lambda, v)$ 下方。

$$\therefore g(\lambda, v) < g_i(\lambda, v) \Rightarrow L(x^*, \lambda, v) \leq P^*$$

4. 拉格朗日对偶问题, Lagrange dual Problem.

由: $g(\lambda, \nu)$ 凹函数 ②.

当 $\lambda \geq 0, \nu \geq 0$ 时, $g(\lambda, \nu)$ 是 P^* 的下确界.
则最好的下确界就是最大化对偶函数,
因此构造原问题的对偶问题.

$$\max_{\lambda, \nu} g(\lambda, \nu)$$

$$\text{s.t. } \sum \lambda_i = 0,$$

由于 $g(\lambda, \nu)$ 为凹函数(性质①)

故该对偶问题一定为凸优化问题,
对应的最优解为 λ^*, ν^* (最优 Lagrange 乘子)

若对偶的最优值为 d^* , 则有 $d^* \leq P^*$

当 $d^* = P^*$ 时, 称为弱对偶.

当 $d^* < P^*$ 时, 称为强对偶.

当 $P^* - d^*$ 称为对偶间隙.

✓ Strong Condition: 用于判断什么情况下强对偶成立.(充分条件)

在原问题是凸问题的条件下, 若 $\exists x \in \text{relint}(D)$

使得约束条件满足 $f_i(x) \leq 0, h_j(x) = 0$

则强对偶成立. (一般大多数原凸问题, 强对偶都是成立的)
($\text{relint}(D)$ 表示 D 除了边界点之外的所有点).

5. KKT 条件.

在对偶间隙 $P^* - d^*$ 为 0 且 L 对 x 可微时,
设 x^*, λ^*, ν^* 分别为原问题和对偶问题最优解.

则以下四组条件称为 KKT 条件:

$$\left\{ \begin{array}{l} \frac{\partial L(x, \lambda^*, \nu^*)}{\partial x} \Big|_{x=x^*} = 0 \quad (\text{stationarity}) \\ \lambda_i^* f_i(x^*) = 0 \quad (\text{complementary slackness}) \\ f_i(x^*) \leq 0, h_j(x^*) = 0 \quad (\text{primal feasibility}) \\ \lambda_i^* \geq 0 \quad (\text{dual feasibility}) \end{array} \right.$$

i. 稳定性条件: 若 x^* 为原问题最优解, 则
 $L(x, \lambda^*, \nu^*)$ 在 x^* 处微分为 0

ii. 互补松弛条件:

当 $\lambda_i^* > 0$ 时, $f_i(x^*) = 0$.

当 $\lambda_i^* = 0$. $f_i(x^*) < 0$ 时, $\lambda_i^* = 0$.

证明: $f_0(x^*) = g(\lambda^*, \nu^*)$

$$\begin{aligned} &= \inf_x \{f_0(x) + \sum_i^m \lambda_i f_i(x) + \sum_j^P \nu_j h_j(x)\} \\ &\stackrel{\text{由: } g(\lambda^*, \nu^*)}{\leq} \stackrel{\text{得证.}}{=} f_0(x^*) + \sum_i^m \lambda_i f_i(x^*) + \sum_j^P \nu_j h_j(x^*) \\ &\leq f_0(x^*). \end{aligned}$$

$$\therefore \sum_{i=1}^m \lambda_i f_i(x^*) = 0$$

III. 原问题可行性: 原问题的最优解必然满足对偶问题的约束条件.

IV. 对偶问题可行性:

对偶问题的解必然满足对偶问题的约束条件.

ey. Lasso 和 KKT 条件.

i. Lasso 问题 $\min_{\beta} \frac{1}{2} \|y - X\beta\|_2^2 + \gamma \|\beta\|_1$,

ii. 写成标准的优化问题:

$$\min_{\beta, z} \frac{1}{2} \|y - z\|_2^2 + \gamma \|\beta\|_1,$$

$$\text{s.t. } z - X\beta = 0$$

iii. Lagrangian.

$$L(\beta, z, u) = \frac{1}{2} \|y - z\|_2^2 + \gamma \|\beta\|_1 + u^T(z - X\beta)$$

iv. 写出对偶函数.

$$g(u) = \inf_{\beta, z} L(\beta, z, u)$$

$$= \min_{\beta, z} \frac{1}{2} \|y - z\|_2^2 + \gamma \|\beta\|_1 + u^T(z - X\beta)$$

$$= \min_z \left\{ \frac{1}{2} \|y - z\|_2^2 + u^T z \right\} + \min_{\beta} \{\gamma \|\beta\|_1 - u^T X\beta\}$$

$$\begin{aligned} \text{利用 } \frac{1}{2} \|y - z\|_2^2 + u^T z &= u^T y - \frac{1}{2} \|u\|_2^2 + \min_{\beta} \{\gamma \|\beta\|_1 - u^T X\beta\}. \\ &= -\frac{1}{2} (\|u\|_2^2 - 2u^T y + \|y\|_2^2) + \frac{1}{2} \|y\|_2^2 + \min_{\beta} \{\gamma \|\beta\|_1 - u^T X\beta\} \\ &= \frac{1}{2} \|y\|_2^2 - \frac{1}{2} \|u - y\|_2^2 - \gamma \max_{\beta} \left\{ \frac{u^T X\beta}{\gamma} - \|\beta\|_1 \right\}. \end{aligned}$$

$$\text{由于 } f^*\left(\frac{x^T u}{\gamma}\right) = \max_{\beta} \left\{ \frac{u^T X\beta}{\gamma} - \|\beta\|_1 \right\},$$

是 $f(\beta) = \|\beta\|_1$ 的对偶函数

\because 范数函数的对偶函数是示性函数

$$= \frac{1}{2} \|y\|_2^2 - \frac{1}{2} \|u - y\|_2^2 - \gamma \mathbb{I}_{\{v: \|v\|_\infty \leq 1\}}\left(\frac{x^T u}{\gamma}\right)$$

v. 得对偶问题.

$$\max_u \frac{1}{2} \|y\|_2^2 - \frac{1}{2} \|u - y\|_2^2$$

$$\text{s.t. } \|\mathbf{X}^T u\|_\infty \leq \gamma.$$

可进一步简化.

$$\min_u \|y - u\|_2^2$$

$$\text{s.t. } \|\mathbf{X}^T u\|_\infty \leq \gamma.$$

vi. KKT 条件.

1. 稳定性条件.

$$0 = \frac{\partial L(\bar{x}_B, z, u^*)}{\partial z} \Big|_{z=z^*} = -(y - z^*) + u^*$$

2. 无互补松弛条件

3. 原问题可行性.

$$z^* - x_B^* = 0$$

4. 对偶问题可行性 $\|x^T u^*\|_\infty \leq \lambda$.

得 KKT 条件为 $\begin{cases} z^* - y + u^* = 0 \\ z^* = x_B^* \\ \|x^T u\|_\infty \leq \lambda. \end{cases}$

即. 便若得到对偶问题最优解 u^* , 则

它与原问题最优解 x_B^* 应满足 $x_B^* = y - u^*$

内优化算法：交替乘子法. Alternating Direction Method of Multipliers.

解决存在 \geq 不等式约束的，更含等式约束的优化类问题。

一般形式：
$$\begin{aligned} & \min_{x,z} f(x) + g(z) \\ \text{s.t. } & Ax + Bz = c. \end{aligned}$$

其中 $x \in \mathbb{R}^n$, $z \in \mathbb{R}^m$ 为优化变量。

$$A \in \mathbb{R}^{pxn}, B \in \mathbb{R}^{pxm}, c \in \mathbb{R}^p$$

为解决这类问题，定义增广拉格朗日. Augmented Lagrangian.

$$L_\rho(x, z, u) = f(x) + g(z) + u^\top (Ax + Bz - c) + \frac{\rho}{2} \|Ax + Bz - c\|_2^2$$

L_ρ 在原 Lagrange 中增加和约束条件有关的惩罚项，其中 $\rho > 0$.

算法流程：每次固定一个变量，只更新一个变量，如此往复。

Step 1: $x^{(k)} = \underset{x}{\operatorname{argmin}} L_\rho(x, z^{(k-1)}, u^{(k-1)})$.

Step 2: $z^{(k)} = \underset{z}{\operatorname{argmin}} L_\rho(x^{(k)}, z, u^{(k-1)})$

Step 3: $u^{(k)} = \underset{u}{\operatorname{argmin}} L_\rho(x^{(k)}, z^{(k)}, u)$

$$u^{(k)} = u^{(k-1)} + \varphi (Ax^{(k)} + Bz^{(k)} - c)$$

✓ 为简化形式. 令 $w = \frac{u}{\rho}$, 则 $L_\rho(x, z, u)$ 可写为

$$L_\rho(x, z, w) = f(x) + g(z) + \frac{\rho}{2} \|Ax + Bz - c + w\|_2^2 - \frac{\rho}{2} \|w\|_2^2$$

相应地, 更新步骤变为.

$$\text{Step 1: } x^{(k)} = \underset{x}{\operatorname{argmin}} f(x) + \frac{\rho}{2} \|Ax + Bz^{(k-1)} - c + w^{(k-1)}\|_2^2$$

$$\text{Step 2: } z^{(k)} = \underset{z}{\operatorname{argmin}} g(z) + \frac{\rho}{2} \|Ax^{(k)} + Bz - c + w^{(k-1)}\|_2^2$$

$$\text{Step 3: } w^{(k)} = w^{(k-1)} + Ax^{(k)} + Bz^{(k)} - c.$$

$$(\text{注意到 } w^{(k)} = w^{(0)} + \sum_{i=1}^K (Ax^{(i)} + Bz^{(i)} - c)).$$

初值 + 约束条件的累计残差和

✓ ADMM 解 lasso.

$$\text{i. lasso 问题. } \min_{\beta} \frac{1}{2} \|y - X\beta\|_2^2 + \gamma \|\beta\|_1,$$

$$\text{ii. 重写为 } \min_{\beta, \alpha} \frac{1}{2} \|y - X\beta\|_2^2 + \gamma \|\alpha\|_1,$$

$$\text{s.t. } \beta - \alpha = 0$$

iii. 构造增强拉格朗日.

$$L_\rho(\beta, \alpha, u) = \frac{1}{2} \|y - X\beta\|_2^2 + \gamma \|\alpha\|_1 + u^T(\beta - \alpha) + \frac{\rho}{2} \|\beta - \alpha\|_2^2$$

iv. 首先更新 β 值.

$$\frac{\partial L}{\partial \beta} = -X^T(y - X\beta) + u + \rho(\beta - \alpha) = 0$$

$$\Rightarrow \beta = (X^T X + \rho I)^{-1}(X^T y + \rho \alpha - u)$$

然后更新 α .

$$\begin{aligned} \arg \min_{\alpha} L_{\rho}(\beta, \alpha, u) &= \arg \min_{\alpha} \left\{ \lambda \| \alpha \|_1 + u^T (\beta - \alpha) + \frac{\rho}{2} \| \beta - \alpha \|_2^2 \right\} \\ &= \arg \min_{\alpha} \left\{ \lambda \| \alpha \|_1 + u^T (\beta - \alpha) + \frac{\rho}{2} \| \beta - \alpha \|_2^2 \right\}, \frac{2}{\rho} \\ &= \arg \min_{\alpha} \left\{ \frac{2\lambda}{\rho} \| \alpha \|_1 + \frac{2}{\rho} u^T (\beta - \alpha) + \| \beta - \alpha \|_2^2 \right\} \\ &= \arg \min_{\alpha} \left\{ \frac{2\lambda}{\rho} \| \alpha \|_1 + \| \frac{u}{\rho} + \beta - \alpha \|_2^2 - \| \frac{u}{\rho} \|_2^2 \right\} \\ &= \arg \min_{\alpha} \left\{ \frac{2\lambda}{\rho} \| \alpha \|_1 + \| \alpha - (\frac{u}{\rho} + \beta) \|_2^2 \right\} \\ &= S_{\frac{2\lambda}{\rho}} \left(\frac{u}{\rho} + \beta \right) \\ &= S_{\frac{u}{\rho}} (w + \beta) \end{aligned}$$

∴ Lasso 更新方法为:

$$\begin{aligned} \beta^{(k)} &= (X^T X + \rho I)^{-1}(X^T y + \rho \cdot \alpha^{(k-1)} - w^{(k-1)}) \\ \alpha^{(k)} &= S_{\frac{2\lambda}{\rho}} (w^{(k-1)} + \beta^{(k)}) \\ w^{(k)} &= w^{(k-1)} + \beta^{(k)} - \alpha^{(k)} \end{aligned}$$